Seaborn: теоретический материал

К 30 заданиям по библиотеке seaborn (начальный и средний уровни)

1. Что такое seaborn

Seaborn — библиотека статистической визуализации, построенная поверх matplotlib и тесно связанная с pandas. Она принимает DataFrame, сама агрегирует данные (считает средние, доверительные интервалы, плотности), строит сложные графики одной строкой и по умолчанию выглядит аккуратнее, чем чистый matplotlib. Каждый график seaborn — это объекты matplotlib, поэтому их можно донастраивать привычными средствами (`plt.title` , `ax.set_xlabel` , `plt.savefig`).

2. Подготовка к работе

Установка: `pip install seaborn` (понадобятся также numpy, pandas, matplotlib).

```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

sns.set_theme()          # включить оформление seaborn по умолчанию
# ... построение графика ...
plt.show()               # показать график (в скриптах обязательно)
```

3. Встроенные наборы данных

Функция `sns.load_dataset('имя')` возвращает готовый DataFrame (при первом обращении нужен интернет — данные скачиваются из репозитория seaborn-data). Список всех наборов: `sns.get_dataset_names()` .

Набор	Что внутри	Основные столбцы
`tips`	чаевые в ресторане	total_bill, tip, sex, smoker, day, time, size
`penguins`	измерения пингвинов	species, island, bill_length_mm, bill_depth_mm, flipper_length_mm, body_mass_g, sex

Набор	Что внутри	Основные столбцы
`iris`	ирисы Фишера	sepal_length, sepal_width, petal_length, petal_width, species
`titanic`	пассажиры «Титаника»	survived, pclass, sex, age, fare, embarked, class, who
`flights`	авиаперевозки 1949–1960	year, month, passengers
`mpg`	характеристики автомобилей	mpg, cylinders, displacement, horsepower, weight, model_year, origin
`diamonds`	бриллианты	carat, cut, color, clarity, price
`fmri`	сигнал фМРТ	subject, timepoint, event, region, signal

Первичный осмотр данных всегда делается средствами pandas: `df.head()`, `df.info()`, `df.describe()`, `df.shape`, `df.columns`, `df.isna().sum()`.

4. Формат данных: long и wide

Seaborn лучше всего работает с «длинными» (tidy) данными: каждая строка — одно наблюдение, каждый столбец — одна переменная. Например, в `tips` пол, день недели и размер счёта — отдельные столбцы, поэтому достаточно написать `x='day', hue='sex'`.

«Широкий» формат (wide) — это таблица-матрица, например «месяцы × годы». Он нужен для тепловых карт. Преобразования делаются в pandas:

```
wide = flights.pivot(index='month', columns='year', values='passengers')   # long -> wide
long = wide.reset_index().melt(id_vars='month', var_name='year', value_name='passengers')  # wide -> long
```

5. Axes-level и figure-level функции

Это ключевое различие в seaborn.

	Axes-level	Figure-level
Примеры	histplot, kdeplot, scatterplot, lineplot, boxplot, barplot, countplot, heatmap, regplot	displot, relplot, catplot, lmplot, pairplot, jointplot

	Axes-level	Figure-level
Где рисуют	на одной системе координат (Axes)	создают собственную Figure
Параметр `ax=`	есть	нет
Размер	`plt.figure(figsize=...)` или `plt.subplots`	`height=` и `aspect=`
Разбиение на подграфики	вручную через `plt.subplots`	параметры `col=`, `row=`
Что возвращают	объект Axes	FacetGrid, PairGrid или JointGrid

Если нужно разместить несколько графиков в одной фигуре вручную — используйте axes-level функции с `ax=`. Если нужна сетка графиков по значениям категориальной переменной — используйте figure-level функции с `col=` / `row=`.

6. Графики распределений

Отвечают на вопрос «как распределены значения переменной?».

`sns.histplot` — гистограмма. Параметры: `x` (или `y` для горизонтальной), `bins` (число столбцов), `binwidth` (ширина столбца), `kde=True` (добавить сглаженную кривую), `stat` (`'count'`, `'density'`, `'probability'`, `'percent'`), `hue` (раздельные распределения по категориям), `multiple` (`'layer'`, `'stack'`, `'dodge'`, `'fill'`), `cumulative=True`.

```
sns.histplot(data=tips, x='total_bill', bins=20, kde=True)
sns.histplot(data=tips, x='total_bill', hue='time', multiple='stack')
```

`sns.kdeplot` — оценка плотности распределения (сглаженная гистограмма). Параметры: `fill=True` (заливка), `bw_adjust` (степень сглаживания: меньше — детальнее), `common_norm=False` (нормировать каждую группу отдельно). Если передать и `x`, и `y`, строится двумерная плотность (линии уровня).

`sns.ecdfplot` — эмпирическая функция распределения: по оси y доля наблюдений, не превышающих значение x. Удобна для сравнения групп без подбора числа столбцов.

`sns.rugplot` — «коврик»: короткие риски на оси для каждого наблюдения; дополняет другие графики.

`sns.displot` — figure-level обёртка: `kind='hist'`, `'kde'` или `'ecdf'`, плюс `col=`, `row=`.

Как читать: форма (симметрично или скошено), число вершин (унимодальное или бимодальное), разброс, выбросы.

7. Графики категориальных данных

Отвечают на вопрос «как значение числовой переменной отличается между категориями?». Общие параметры: `x`, `y`, `hue`, `order`, `hue_order`, `orient`.

Подсчёт и оценка

- `sns.countplot(data=df, x='col')` — количество наблюдений в каждой категории (ось y считается сама).
- `sns.barplot(data=df, x='cat', y='num')` — по умолчанию высота столбца равна среднему, а чёрная «усика» показывает 95%-й доверительный интервал. Параметры: `estimator` (например, `'median'` или `sum`), `errorbar` (`('ci', 95)`, `'sd'`, `None`).
- `sns.pointplot` — те же оценки, но точками и линиями; удобна для сравнения нескольких групп.

Распределения внутри категорий

- `sns.boxplot` — «ящик с усами»: линия внутри — медиана, границы ящика — квартили Q1 и Q3, усы тянутся до 1,5·IQR, точки за усами — выбросы.
- `sns.violinplot` — «скрипка»: форма показывает плотность распределения; параметры `inner` (`'box'`, `'quartile'`, `'point'`, `None`), `split=True` (две половины скрипки для двух значений `hue`).
- `sns.boxenplot` — расширенный boxplot для больших выборок.

Все наблюдения

- `sns.stripplot` — точки с небольшим случайным смещением (`jitter`).
- `sns.swarmplot` — точки без перекрытия (на больших выборках медленный).

`sns.catplot(kind=...)` — figure-level функция, объединяющая всё выше: `kind='count'`, `'bar'`, `'box'`, `'violin'`, `'strip'`, `'swarm'`, `'point'`, `'boxen'`; поддерживает `col=`, `row=`, `height=`, `aspect=`.

```
sns.boxplot(data=tips, x='day', y='total_bill', hue='sex')
sns.catplot(data=tips, x='day', y='tip', kind='violin', col='time')
```

Примечание: в новых версиях seaborn (0.13+) при указании `palette` без `hue` возникает предупреждение. Решение: `hue='x_column', legend=False`.

8. Графики связей между переменными

Отвечают на вопрос «как связаны две числовые переменные?».

`sns.scatterplot` — диаграмма рассеяния. Дополнительные измерения кодируются через `hue` (цвет), `size` (размер точки), `style` (форма маркера). Также полезны `alpha` (прозрачность при наложении точек), `sizes=(мин, макс)`.

`sns.lineplot` — линейный график. Особенности: данные автоматически сортируются по x; если для одного x несколько значений y, линия показывает среднее, а полупрозрачная полоса — доверительный интервал (`errorbar=None` отключает полосу, `estimator=None` рисует все данные как есть). Параметры `hue`, `style`, `markers=True`.

`sns.relplot` — figure-level обёртка: `kind='scatter'` или `'line'`, плюс `col=`, `row=`, `col_wrap=`.

```
sns.scatterplot(data=tips, x='total_bill', y='tip', hue='time', size='size')
sns.relplot(data=tips, x='total_bill', y='tip', col='day', col_wrap=2)
```

9. Регрессионные графики

`sns.regplot` — диаграмма рассеяния плюс линия линейной регрессии с доверительной полосой. Параметры: `order` (степень полинома), `ci` (уровень доверительного интервала, `None` — убрать), `scatter_kws={'alpha': 0.5}`, `line_kws={'color': 'red'}`, `logx=True`.

`sns.lmplot` — figure-level версия: поддерживает `hue=`, `col=`, `row=` (отдельная линия регрессии для каждой группы).

`sns.residplot` — график остатков регрессии; если точки хаотично распределены вокруг нуля, линейная модель подходит.

10. Матричные графики

`sns.heatmap` — тепловая карта: значения матрицы кодируются цветом. Данные должны быть именно матрицей (индекс и столбцы — подписи осей). Откуда её взять: `df.corr(numeric_only=True)` (корреляции), `df.pivot(...)` или `pd.pivot_table(...)`, `pd.crosstab(...)`.

Параметры: `annot=True` (значения в ячейках), `fmt='.2f'` (формат чисел; для целых `'d'`), `cmap` (`'coolwarm'`, `'viridis'`, `'Blues'`), `center=0` (середина цветовой шкалы), `vmin`, `vmax`, `linewidths`, `square=True`, `cbar=False`.

```
corr = penguins.corr(numeric_only=True)
sns.heatmap(corr, annot=True, fmt='.2f', cmap='coolwarm', center=0)
```

`sns.clustermap` — тепловая карта, у которой строки и столбцы переупорядочены по иерархической кластеризации (сверху и слева рисуются дендрограммы). Параметры `standard_scale=0/1` и `z_score=0/1` нормируют данные по строкам или столбцам.

11. Сетки графиков

`sns.pairplot(data, hue=..., vars=[...], kind='scatter'|'reg', diag_kind='hist'|'kde', corner=True)` — матрица попарных диаграмм рассеяния для всех числовых столбцов, на диагонали — распределения. `corner=True` оставляет только нижний треугольник.

`sns.jointplot(data, x, y, kind=...)` — диаграмма двух переменных вместе с распределением каждой на полях. Значения `kind`: `'scatter'`, `'kde'`, `'hist'`, `'hex'`, `'reg'`, `'resid'`. Поддерживает `hue=`.

`sns.FacetGrid(data, col=..., row=..., hue=..., height=...)` — универсальная сетка: создаётся «каркас», затем на каждый подграфик применяется функция:

```
g = sns.FacetGrid(tips, col='time', row='smoker', height=3)
g.map_dataframe(sns.histplot, x='total_bill')
g.set_axis_labels('Сумма счёта', 'Количество')
g.set_titles(col_template='{col_name}', row_template='{row_name}')
g.add_legend()
```

Общий заголовок для сетки: `g.figure.suptitle('Заголовок', y=1.03)`.

12. Оформление: темы и палитры

Единая настройка: `sns.set_theme(style='whitegrid', palette='Set2', context='talk', font_scale=1.1)`.

- `style` — фон и сетка: `'darkgrid'` (по умолчанию), `'whitegrid'`, `'dark'`, `'white'`, `'ticks'`.
- `context` — масштаб элементов: `'paper'`, `'notebook'` (по умолчанию), `'talk'`, `'poster'`.

- `palette` — набор цветов.

Виды палитр:

- качественные (для категорий): `'deep'`, `'pastel'`, `'muted'`, `'bright'`, `'Set2'`, `'tab10'`;
- последовательные (для упорядоченных значений): `'Blues'`, `'viridis'`, `'rocket'`, `'mako'`;
- расходящиеся (с нейтральной серединой): `'coolwarm'`, `'vlag'`, `'RdBu'`.

Просмотр палитры: `sns.color_palette('Set2', 5)` (в Jupyter выводится цветными квадратами). Добавление `_r` к названию переворачивает палитру (`'Blues_r'`).

Дополнительно: `sns.despine()` убирает верхнюю и правую рамки; `with sns.axes_style('white'):` применяет стиль временно; `sns.move_legend(ax, 'upper left', bbox_to_anchor=(1, 1))` выносит легенду за пределы графика.

13. Совместная работа с matplotlib

Axes-level функции seaborn можно размещать в сетке matplotlib:

```
fig, axes = plt.subplots(2, 2, figsize=(12, 8))
sns.histplot(data=tips, x='total_bill', ax=axes[0, 0])
sns.boxplot(data=tips, x='day', y='tip', ax=axes[0, 1])
axes[0, 0].set_title('Распределение счетов')
axes[0, 1].set_xlabel('День недели')
axes[0, 1].tick_params(axis='x', rotation=45)
fig.suptitle('Анализ чаевых')
plt.tight_layout()
plt.savefig('tips.png', dpi=300, bbox_inches='tight')
plt.show()
```

Для подписей и заголовков axes-level графика: `ax.set(title='...', xlabel='...', ylabel='...')`. Для figure-level графика: `g.set_axis_labels(...)`, `g.set_titles(...)`, `g.savefig('имя.png')`. Размер обычной фигуры задаётся через `figsize`, а figure-level графика — через `height` и `aspect`.

14. Типичные ошибки

- **`figsize` не действует на figure-level график.** Используйте `height=` и `aspect=` (ширина = height × aspect).

- **Параметр `ax=` у figure-level функции вызывает ошибку.** Он есть только у axes-level функций.
- **Пропуски (NaN).** В `penguins` и `titanic` есть пропущенные значения; при необходимости используйте `df.dropna()` или `df.dropna(subset=[...])`.
- **Тепловая карта не строится из исходного DataFrame с текстовыми столбцами.** Сначала получите матрицу: `corr(numeric_only=True)` или `pivot`.
- **Опечатка в названии столбца.** Проверяйте `df.columns`; регистр важен.
- **Наложение подписей на оси.** Поверните их: `plt.xticks(rotation=45)` или `ax.tick_params(axis='x', rotation=45)`.
- **Забыли `plt.show()`** (в скрипте график не появится) или вызвали его до сохранения (`savefig` нужно вызывать до `show`).
- **Неверная палитра для типа данных:** для категорий — качественная, для порядковых или числовых значений — последовательная, для отклонений от нуля — расходящаяся.